

Tema 1

Introducción a las bases de datos

1. [Sistemas de información](#)
2. [Tipos de sistemas de información](#)
 - 2.1. Orientados a procesos (sistemas de ficheros)
 - 2.2. Orientados a datos (bases de datos)
3. [Niveles de abstracción en una base de datos. Arquitectura de la base de datos.](#)
4. [Sistemas Gestores de bases de datos](#)
5. [Componentes de los SGBD](#)
 - 5.1. Funciones <-> Lenguajes de los SGBD
 - 5.2. Diccionario de datos
6. [Funcionamiento del SGBD](#)
7. [Estructuras operacionales](#)
8. [Tipos de SGBD según el modelo lógico](#)
 - 8.1. Modelo jerárquico
 - 8.2. Modelo en red (Codasyl)
 - 8.3. Modelo relacional
 - 8.4. Modelo orientado a objetos
 - 8.5. Modelo objeto-relacional
9. [Recursos humanos de la base de datos](#)
 - 9.1. Informáticos
 - 9.2. Usuarios
10. [Aspectos legales: la LOPD y el RGPD](#)
11. [Bases de datos distribuidas](#)
12. [Big-Data](#)
13. [Anexo: Estándares](#)

1.- Sistemas de información

La necesidad de gestionar datos

En el mundo actual existe una cada vez mayor demanda de datos. Esta demanda siempre ha sido patente en empresas y sociedades, pero en estos años la demanda todavía se ha disparado más debido al acceso multitudinario a las redes como Internet. Los medios de comunicación recopilan, elaboran y difunden grandes cantidades de información. De todas estas necesidades surge una de las principales aplicaciones de la informática que son las bases de datos (BD). El conocimiento y diseño de las mismas es el objetivo de este módulo.

En informática se conoce como **dato** a cualquier elemento informativo que tenga relevancia para un usuario. Desde el primer momento de esta ciencia se ha reconocido al dato como al elemento fundamental de trabajo en un ordenador. Por ello se han realizado numerosos estudios y aplicaciones para mejorar la gestión que desde las computadoras se realiza de los datos.

La escritura fue la herramienta que permitió al ser humano poder gestionar bases cada vez más grandes de datos. Con el tiempo aparecieron herramientas como archivos, cajones, carpetas y fichas en las que se almacenaban los datos.

Antes de la aparición del ordenador, el tiempo requerido para manipular estos datos era enorme. Sin embargo, el proceso de aprendizaje era relativamente sencillo ya que se usaban elementos que el usuario reconocía perfectamente.

Por esa razón, la informática ha adaptado sus herramientas para que los elementos que el usuario maneja en el ordenador se parezcan a los que utilizaba manualmente. Así en informática se sigue hablando de ficheros, formularios, carpetas, directorios....

Sistemas de información

Según la RAE, la definición de sistema es el “conjunto de cosas que relacionadas entre sí ordenadamente contribuyen a un determinado objetivo”.

Un sistema de información es, pues, un conjunto de recursos físicos, humanos y de protocolo encaminados a gestionar y organizar información.

Hoy en día encontramos multitud de sistemas de información en empresas, publicaciones, ayuntamientos, ministerios, organizaciones, organismos oficiales, y también en periódicos, emisoras de radio y TV, etc.

Componentes de un sistema de información electrónico

Debido a la cantidad de datos a manejar, los sistemas de información han incorporado elementos electrónicos para poder automatizar y sistematizar el almacenamiento y gestión de la información, de ahí que se les denomine sistemas de información electrónicos; cuyos componentes son:

- **Datos.** Se trata de la información relevante que almacena y gestiona el sistema de información. Ejemplos de datos son: *Sánchez, 12764569F, Calle Mayo 5, Azul...*
- **Hardware.** Equipamiento físico que se utiliza para gestionar los datos, es decir, cada uno de los dispositivos electrónicos que permiten el funcionamiento del sistema de información.
- **Software.** Aplicaciones informáticas que se encargan de la gestión de la base de datos.
- **Recursos humanos.** Personal que maneja el sistema de información.

2.- Tipos de sistemas de información

En la evolución de los sistemas de información ha habido dos puntos determinantes que han formado los dos tipos fundamentales de sistemas de información.

2.1.- Sistemas de información orientados al proceso (o sistemas de ficheros)

En estos sistemas de información se crean diversas aplicaciones (software) para gestionar diferentes aspectos del sistema. Cada aplicación realiza unas determinadas operaciones. Los datos de dichas aplicaciones se almacenan en archivos digitales dentro de las unidades de almacenamiento del ordenador (a veces en archivos binarios, o en hojas de cálculo, o incluso en archivos de texto). Cada programa almacena y utiliza sus propios datos de forma un tanto caótica. La **única ventaja** de este sistema es que los **procesos son independientes**, por lo que la modificación de uno no afectaba al resto. Pero tiene grandes inconvenientes:


- **Datos redundantes**, ya que se repiten continuamente
- **Datos inconsistentes**. Si un proceso cambia sus datos y el resto de procesos no, el mismo dato puede tener valores distintos según qué aplicación acceda a él.
- **Coste de almacenamiento elevado**. Al almacenarse varias veces el mismo dato, se requiere más espacio en los discos, con lo que se agotarán antes.
- **Difícil acceso a los datos**. Cada vez que se requiera una consulta no prevista inicialmente hay que modificar el código de las aplicaciones o incluso crear una nueva aplicación.
- **Dependencia de los datos a nivel físico**. Para poder saber cómo se almacenan los datos, es decir, qué estructura se utiliza de los mismos, necesitamos ver el código de la aplicación; es decir el código y los datos no son independientes. La descripción de cada dato se encuentra dentro del programa que lo usa.
- **Tiempos de procesamiento elevados** al no poder optimizar el espacio de almacenamiento.
- **Dificultad para el acceso simultáneo a los datos**. Es casi imposible de conseguir ya que se utilizan archivos que no admiten esta posibilidad. Dos usuarios no pueden acceder a los datos de forma concurrente.
- **Dificultad para administrar la seguridad del sistema**, ya que cada aplicación se crea independientemente; siendo muy difícil establecer criterios de seguridad uniformes.



A estos sistemas también se les denomina sistemas de gestión de ficheros. Los primeros sistemas informáticos eran de este tipo. En muchas empresas y organizaciones todavía se siguen usando este tipo de sistema, debido a que han ido haciendo una implantación aislada de las distintas áreas de negocio que deseaban gestionar informáticamente y el coste que supondría cambiar a otro tipo de sistema ahora sería inasumible.

2.2.- **Sistemas de información orientados a los datos:** **Bases de datos (BD)**

En este tipo de sistemas los datos se centralizan en una base de datos común a todas las aplicaciones. Estos serán los sistemas que estudiaremos en este curso. En estos sistemas, los datos se almacenan en una única estructura lógica que es utilizable por las aplicaciones. A través de esa estructura se accede a los datos, que son comunes a todas las aplicaciones. Cuando una aplicación modifica un dato, la modificación de dicho dato será visible para el resto de aplicaciones.



Ventajas:

- **Independencia de los datos, los programas y los procesos.** Esto permite modificar los datos sin modificar el código de las aplicaciones. Por ejemplo, si se suprime el dato fecha de nacimiento de los alumnos y se añaden, por ejemplo, los datos referentes a las aulas, este cambio no debe afectar a las aplicaciones que no trabajen con la fecha de nacimiento.
- **Menor redundancia.** No hace falta tanta repetición de datos. Sólo se indica la forma en la que se relacionan los datos.
- **Integridad de los datos.** Proviene en gran medida de la no redundancia. Existe mayor dificultad de perder relaciones entre los datos o de realizar incoherencias con ellos. Para mejorar la integridad, las bases de datos disponen de mecanismos para imponer reglas de integridad o restricciones.
- **Mayor seguridad en los datos,** al permitir limitar el acceso a los usuarios. Cada tipo de usuario podrá acceder a unas cosas. Por ejemplo, el personal administrativo de la universidad puede no tener acceso a las notas de los alumnos. Sin embargo, los profesores acceden a las notas, pero no al pago de matrícula. Los mecanismos de seguridad en una base de datos deben asegurar la confidencialidad de ciertos datos personales. Algunas de estas medidas de seguridad son: distintos tipos de usuarios con distintas

autorizaciones, contraseñas, encriptaciones, copias de respaldo seguras. También se dispone de mecanismos que facilitan la realización de copias de seguridad para evitar la pérdida de datos por fallos físicos.


- **Datos más documentados.** Gracias a los metadatos (datos sobre la estructura de los datos) que permiten describir la información de la base de datos.
- **Acceso a los datos más eficiente.** La organización de los datos produce un resultado más optimizado en cuanto al rendimiento.
- **Menor espacio de almacenamiento,** gracias a una mejor estructuración de los datos.
- **Acceso simultáneo a los datos.** Es más fácil controlar el acceso de usuarios de forma concurrente. Hoy en día son frecuentes las bases de datos que admiten acceso simultáneo de miles de usuarios a la vez. Si todos los usuarios realizan consultas, el problema que se puede producir es la disminución de rendimiento. Si se dispone de una buena base de datos, este problema puede ser resuelto ajustando convenientemente la estructura física y lógica de la base de datos (soportes ultra-rápidos, buffers adecuados, ajuste al tamaño real de los datos, etc.). Cuando más de un usuario actualiza datos de la misma base de datos, puede haber interferencias. Para resolver este problema se usa el concepto de transacción: conjunto de operaciones simples que se ejecutan como una unidad. Cuando se ejecuta una transacción, o se realizan todas las acciones que comporta, o no se realiza ninguna. De esta forma se asegura que no se produzcan incoherencias.

Ejemplo de transacción: Supongamos que en un banco una persona desea realizar un traspaso de dinero desde una cuenta X a otra cuenta Y. En primer lugar, debe restar de la cuenta X y luego realizar la suma al saldo de la cuenta Y. Esta operación se debe realizar de forma que se realicen las dos acciones o ninguna. Si en medio de las dos acciones se produce un corte de electricidad, se haría el cargo en X, pero no el abono en Y y la base de datos quedaría inconsistente, puesto que no refleja la realidad.

También entre transacciones que se ejecutan concurrentemente se pueden producir problemas de interferencia que hagan obtener resultados erróneos o que comporten la pérdida de la integridad de los datos.

Ejemplos de la interferencia entre transacciones:

- 1) Imaginemos que una transacción que transfiere dinero de X a Y se ejecuta concurrentemente con una transacción que observa el saldo de las cuentas Y y X, en este orden, y nos muestra su suma. Si la ejecución de forma concurrente de las dos transacciones casualmente es tal que la transferencia se ejecuta entre la ejecución de las dos lecturas de la transacción de suma, puede producir resultados incorrectos. Además, si decide escribirlos en la base de datos, ésta quedará inconsistente. Podemos observar claramente este ejemplo en el siguiente gráfico.



2) Si simultáneamente con un generoso programa que aumenta la nota de los alumnos en un 30%, se ejecuta un programa que determina la nota media de todos los alumnos de una determinada asignatura, se podrá encontrar a alumnos ya gratificados y a otros no gratificados, algo que producirá resultados erróneos.

Estos son sólo dos ejemplos de las diferentes consecuencias negativas que puede tener la interferencia entre transacciones en la integridad de la base de datos y en la corrección del resultado de las consultas.

Nos interesará que el sistema ejecute las transacciones de forma que no se interfieran; es decir, que queden aisladas unas de otras. Para conseguir que las transacciones se ejecuten como si estuviesen aisladas, se utilizan distintas técnicas. La más conocida es el bloqueo (lock). El bloqueo de unos datos en beneficio de una transacción consiste en poner limitaciones a los accesos que las demás transacciones podrán hacer a estos datos. Cuando se provocan bloqueos, se producen esperas, retenciones y, en consecuencia, el sistema es más lento. Los sistemas de gestión de bases de datos se esfuerzan en minimizar estos efectos negativos.

Desventajas:

- **Instalación costosa.** El control y administración de las bases de datos requiere de un software y hardware poderoso.
- **Requiere personal cualificado** debido a la dificultad de manejo de este tipo de sistemas.
- **Implantación larga y difícil** debido a los puntos anteriores. La adaptación del personal es mucho más complicada y lleva bastante tiempo.
- **Ausencia de estándares reales,** lo cual significa una excesiva dependencia hacia los sistemas comerciales del mercado. Hoy en día esto ha mejorado

significativamente ya que una gran parte de esta tecnología está aceptada como estándar de hecho.


Por lo tanto, en términos informáticos, se puede definir una **base de datos** como una colección de datos relacionados, estructurados y organizados entre sí, junto con el conjunto de programas que acceden y gestionan esos datos procurando seguridad, integridad y concurrencia.

3.- Niveles de abstracción de una base de datos. Arquitectura de una base de datos.

En las bases de datos actuales, según el **modelo estándar ANSI**, se utilizan **tres esquemas para representar los datos**:

- El **esquema externo** refleja la información preparada para el usuario final.
- El **esquema conceptual** refleja los datos y relaciones de la base de datos.
- El **esquema interno** refleja la preparación de los datos para ser almacenados, siendo éste el esquema más cercano a la organización real de los datos.

En definitiva, el modelo ANSI es una propuesta teórica sobre cómo debe funcionar un sistema gestor de bases de datos. Su idea se puede observar en la siguiente figura:



El paso de un esquema a otro se realiza utilizando una interfaz o función de traducción. En su modelo, ANSI no indica cómo se debe realizar esta función, sólo que debe existir.

Esquema físico (nivel interno)

Representa la forma en la que están almacenados los datos. Esta visión sólo la requiere el administrador, que la necesita para poder gestionar más eficientemente la base de datos.

En este esquema se habla de archivos, directorios o carpetas, unidades de disco, servidores...

Esquema conceptual (nivel conceptual)

Se trata de un esquema teórico de los datos en el que figuran organizados en estructuras reconocibles del mundo real y en el que también aparece la forma en la que los datos se relacionan. Este esquema es el paso intermedio que permite modelar un problema real a su forma correspondiente en el ordenador, siendo la base del diseño de una base de datos. Como se verá más adelante, es el primer paso a realizar al crear una base de datos. Oculta detalles de almacenamiento. El esquema conceptual lo realizan diseñadores o analistas.

Esquema externo (nivel de visión, de usuario)

Se trata de la visión de los datos que poseen los usuarios finales a través de las aplicaciones. Las aplicaciones creadas por los desarrolladores abstraen la realidad conceptual de modo que el usuario no conoce las relaciones entre los datos, como tampoco conoce todos los datos que realmente se almacenan. Realmente, cada aplicación produce un esquema externo o vista de usuario diferente (aunque algunos pueden coincidir). El conjunto de todas las vistas de usuario es lo que se denomina esquema externo global.

4.- Sistemas gestores de bases de datos (SGBD)

Un sistema gestor de bases de datos o **SGBD** (aunque se suele utilizar más a menudo las siglas **DBMS** procedentes del inglés, *Data Base Management System*) es el software que permite a los usuarios procesar, describir, administrar y recuperar los datos almacenados en una base de datos.

En estos sistemas se proporciona un conjunto coordinado de programas, procedimientos y lenguajes que permiten a los distintos usuarios realizar sus tareas habituales con los datos, garantizando además la seguridad de los mismos. El éxito del SGBD reside en mantener la seguridad e integridad de los datos.

Lógicamente tiene que proporcionar herramientas a los distintos usuarios. Entre estas **herramientas** están:

- **Herramientas para la creación y especificación de los datos, así como para definir la propia estructura de la base de datos.**
- **Herramientas para crear y administrar la estructura física** requerida en las unidades de almacenamiento.
- **Herramientas para la manipulación de los datos** de las bases de datos, para añadir, modificar, suprimir o consultar datos.
- **Herramientas de recuperación** en caso de desastre.
- **Herramientas para la creación de copias de seguridad.**
- **Herramientas para la exportación e importación de datos.**
- **Herramientas para el control de accesos** (seguridad, permisos, concurrencia).

5.- Componentes de los SGBD

5.1.- Funciones <-> Lenguajes de los SGBD

Los SGBD tienen que realizar tres tipos de funciones:

- **Función de descripción o definición**

Permite al diseñador de la base de datos crear las estructuras apropiadas para integrar adecuadamente los datos. Esta función se realiza mediante el **lenguaje de descripción de datos (DDL – Data Definition Language)**. Mediante ese lenguaje:

- Se definen las estructuras de datos.
- Se definen las relaciones entre los datos.
- Se definen las reglas que han de cumplir los datos.

- **Función de manipulación**

Permite modificar y utilizar los datos de la base de datos. Se realiza mediante el **lenguaje de modificación de datos (DML – Data Manipulation Language)**. Mediante ese lenguaje se puede:

- Añadir datos.
- Eliminar datos.
- Modificar datos.
- Buscar datos.

Actualmente se suele distinguir aparte la función de buscar datos en la base de datos (**función de consulta**), para lo cual se proporciona un **lenguaje de consulta de datos (DQL – Data Query Language)**. Este lenguaje de consulta, con **SQL (Structured Query Language)** como su representante más extendido y estandarizado, proporciona a las bases de datos uno de sus objetivos fundamentales: poder realizar consultas no predefinidas y complejas por cualquier usuario. Esto, sin detrimento de la posibilidad de escribir programas con consultas incorporadas, como, por ejemplo, para procesos repetitivos.

- **Función de control**

Mediante esta función los administradores poseen mecanismos para proteger las visiones de los datos permitidas a cada usuario, además de proporcionar elementos de creación y modificación de esos usuarios.

Se suelen incluir aquí las tareas de copia de seguridad, carga de ficheros, auditoría, protección ante ataques externos, configuración del sistema...

El lenguaje que implementa esta función es el **lenguaje de control de datos (DCL – Data Control Language)**.

5.2.- Diccionario de datos

El diccionario de datos es el lugar donde se deposita información acerca de todos los datos que forman la base de datos. Es una guía en la que se describe la base de datos y los objetos que la forman. Es un catálogo en el que se almacenan las descripciones de los datos, denominadas metadatos (datos acerca de los datos).


Normalmente, un diccionario de datos **almacena**:

- Definición de todos los objetos de la base de datos.
- Nombre, tipo y tamaño de los datos.
- Relaciones entre los datos.
- Restricciones de integridad sobre los datos.
- Espacio asignado y utilizado por los datos.
- Nombre de los usuarios autorizados a acceder a la base de datos.
- Esquemas externos, conceptual e interno, así como la correspondencia entre los esquemas.
- Estadísticas de utilización, tales como la frecuencia de las transacciones y el número de accesos realizados a los objetos de la base de datos.

Debe estar almacenado en un soporte con acceso directo para la fácil recuperación de la información.

6.- Funcionamiento del SGBD

El siguiente esquema presenta el funcionamiento típico de un SGBD:



El esquema anterior reproduce la comunicación entre un proceso de usuario que desea acceder a los datos y el SGBD:


- (1) El proceso lanzado por el usuario llama al SGBD indicando la porción de la base de datos que se desea tratar (por ejemplo, listar facturas pendientes).
- (2) El SGBD traduce la llamada a términos del esquema lógico de la base de datos. Accede al esquema lógico comprobando derechos de acceso y la traducción física (normalmente los metadatos se guardan en una zona de memoria global y no en el disco) (tabla facturas, clientes, pagos...)
- (3) El SGBD obtiene el esquema físico (tablespace USERS, data.dbf)

- (4) El SGBD traduce la llamada a los métodos de acceso del Sistema Operativo que permiten acceder realmente a los datos requeridos (*pista y sector a leer*).
- (5) El Sistema Operativo **accede** a los datos tras traducir las órdenes dadas por el SGBD (*lectura*).
- (6) Los datos pasan del disco a una memoria intermedia o *buffer*. En ese buffer se almacenarán los datos según se vayan recibiendo.
- (7) Los datos pasan del buffer al área de trabajo del usuario del propio proceso del usuario. Los pasos 6 y 7 se repiten hasta que se envíe toda la información al proceso de usuario.
- (8) En el caso de que haya errores en cualquier momento del proceso, el SGBD devuelve indicadores en los que manifiesta si ha habido errores o advertencias a tener en cuenta. Esto se indica al área de comunicaciones del proceso de usuario. Si las indicaciones son satisfactorias, los datos serán utilizables por el proceso de usuario.

7.- Estructuras operacionales

Actualmente, casi todos los SGBD poseen la misma idea operacional en la que se entiende que la base de datos se almacena en un servidor y hay una serie de clientes que pueden acceder a los datos del mismo. Las posibilidades son:

- **Estructura Cliente-Servidor.** Estructura clásica, la base de datos y su SGBD están en un servidor al cual acceden los clientes. El cliente posee software que permite al usuario enviar instrucciones al SGBD en el servidor y recibir los resultados de estas instrucciones. Para ello, el software cliente y el servidor deben utilizar software de comunicaciones en red.
- **Cliente multi-servidor.** Ocurre cuando los clientes acceden a datos situados en más de un servidor. También se conoce esta estructura como **base de datos distribuida**. El cliente no sabe si los datos están en uno o más servidores, ya que el resultado es el mismo independientemente de dónde se almacenan los datos. En esta estructura hay un servidor de aplicaciones que recibe las peticiones y es el encargado de traducirlas a los distintos servidores de datos para obtener los resultados.




- **Cliente-Servidor con facilidades de usuario-Servidor de base de datos.** Se trata de una forma de conexión por el que los clientes no conectan

directamente con la base de datos sino con un intermediario (normalmente un **Servidor Web**) que tiene una mayor facilidad para comunicarse con los usuarios. Ese servidor se encarga de traducir lo que el cliente realiza a una forma entendible por la base de datos.

8.- Tipos de SGBD según su modelo lógico

Una de las características de los sistemas de bases de datos es que proporcionan cierto nivel de abstracción de datos al ocultar las características sobre el almacenamiento físico, que la mayoría de los usuarios no necesitan conocer. Los **modelos de datos** son los instrumentos básicos para ofrecer dicha abstracción.

Se pueden tener distintos modelos de datos, dependiendo del nivel en que se quiera representar la información.



Como se ha visto en los apartados anteriores, la arquitectura de una base de datos suele estructurarse en tres niveles (modelo físico, modelo conceptual y modelo externo). En la realidad, el modelo ANSI se modifica para que existan dos modelos internos:

- El **modelo conceptual**, primer paso en la representación del mundo real de forma esquemática, con conceptos muy cercanos a cómo los usuarios ven los datos.
- El **modelo lógico**, un paso más profundo en los niveles de abstracción, con una representación de los datos más cercana al almacenamiento físico.

El modelo lógico utilizado, por ser más cercano al nivel físico, define el tipo de base de datos a emplear.

Resumiendo:

- El modelo conceptual es independiente del SGBD que se vaya a utilizar. El lógico depende de un tipo de SGBD en particular.
- El modelo lógico está más cerca del modelo físico, el que utiliza internamente el ordenador.
- El modelo conceptual es el más cercano al usuario, siendo el lógico el encargado de establecer el paso entre el modelo conceptual y el modelo físico del sistema.

El **modelo conceptual más utilizado** es el **modelo Entidad-Relación** (o Entidad Interrelación, que se verá en el tema siguiente).

A continuación, se comentarán los **modelos lógicos más importantes**.

8.1.- Modelo jerárquico

Era utilizado por los primeros SGBD, desde que IBM lo definió para su IMS (*Information Management System*, Sistema Administrador de Información) en 1970. Se le llama también modelo en árbol debido a que utiliza una estructura en árbol para organizar los datos.

La información se organiza con una jerarquía en la que la relación entre las entidades de este modelo siempre es del tipo padre / hijo. De esta forma, hay una serie de nodos que contendrán atributos y que se relacionarán con nodos hijos de forma que puede haber más de un hijo para el mismo padre (pero un hijo sólo tiene un padre).

Los datos de este modelo se almacenan en estructuras lógicas llamadas segmentos. Los segmentos se relacionan entre sí utilizando arcos.

La forma visual de este modelo es de árbol invertido, en la parte superior están los padres y en la inferior los hijos.

Este esquema está en absoluto desuso ya que no es válido para modelar la mayoría de problemas de bases de datos.

8.2.- Modelo en red (Codasyl)

Es un modelo que ha tenido una gran aceptación (aunque apenas se utiliza actualmente). En especial se hizo popular la forma definida por Codasyl a principios de los 70, convirtiéndose en el modelo en red más utilizado.

El modelo en red organiza la información en registros (también llamados nodos) y enlaces. En los registros se almacenan los datos, mientras que los enlaces permiten relacionar estos datos. Las bases de datos en red son parecidas a las jerárquicas sólo que en ellas puede haber más de un padre.

En este modelo se pueden representar perfectamente cualquier tipo de relación entre los datos (aunque el Codasyl restringía un poco las relaciones posibles), pero hace muy complicado su manejo.

8.3.- Modelo relacional

En este modelo los datos se organizan en tablas cuyos datos se relacionan. Es el modelo más popular y se describe con más detalle en los temas siguientes.

8.4.- Modelo orientado a objetos

Desde la aparición de la programación orientada a objetos (*POO u OOP*) se empezó a pensar en bases de datos adaptadas a estos lenguajes. La programación orientada a objetos permite cohesionar datos y procedimientos, haciendo que se diseñen estructuras que poseen datos (propiedades) en las que se definen los procedimientos (operaciones) que pueden realizar con los datos. En las bases orientadas a objetos se utiliza esta misma idea.

A través de este concepto se intenta que estas bases de datos consigan arreglar las limitaciones de las relacionales. Se supone que son las bases de datos de tercera generación (la primera fue las bases de datos en red y la segunda las relacionales), lo que significa que el futuro parece estar a favor de estas bases de datos. Pero siguen sin reemplazar a las relacionales, aunque son el tipo de base de datos que más está creciendo en los últimos años.

Su modelo conceptual se suele diseñar en UML (*Unified Modeling Language – Lenguaje unificado de modelado*) y el lógico actualmente en **ODMG** (*Object Data Management Group*, grupo de administración de objetos de datos, organismo que intenta crear estándares para este modelo).

8.5.- Modelo objeto-relacional

Trata de ser un híbrido entre el modelo relacional y el orientado a objetos. El problema de las bases de datos orientadas a objetos es que requieren reinvertir capital y esfuerzos de nuevo para convertir las bases de datos relacionales en bases de datos orientadas a objetos. En las bases de datos objeto-relacionales se intenta conseguir una compatibilidad relacional dando la posibilidad de integrar mejoras de la orientación a objetos.

Estas bases de datos se basan en el estándar SQL99. En ese estándar se añade a las bases relacionales la posibilidad de almacenar procedimientos de usuario, tipos definidos por el usuario, consultas recursivas, bases de datos OLAP (On-Line Analytical Processing - procesamiento analítico en línea), tipos LOB (*Oracle Large Objects*), ...

9.- Recursos humanos de las bases de datos

En el desarrollo y manipulación de una base de datos intervienen muchas personas. Antes ya se había hablado por encima de cuatro tipos de usuarios: administradores, desarrolladores, diseñadores y usuarios finales. Ahora vamos a profundizar aún más esta clasificación.

9.1.- Informáticos

Lógicamente son los profesionales que definen y preparan la base de datos. Pueden ser:

- **Directivos.** Organizadores y coordinadores del proyecto a desarrollar y máximos responsables del mismo. Esto significa que son los encargados de decidir los recursos que se pueden utilizar, planificar el tiempo y las tareas, la atención al usuario y de dirigir las entrevistas y reuniones pertinentes.
- **Analistas.** Son los encargados de controlar el desarrollo de la base de datos aprobada por la dirección. Normalmente son además los **diseñadores de la base de datos** (especialmente de los esquemas interno y conceptual) y los **directores de la programación** de la misma.
- **Administradores de las bases de datos.** Encargados de crear el esquema interno de la base de datos, que incluye la planificación de copias de seguridad, gestión de usuarios y permisos y creación de los objetos de la base de datos.

- **Desarrolladores o programadores.** Encargados de la realización de las aplicaciones de usuario de la base de datos.
- **Equipo de mantenimiento.** Encargados de dar soporte a los usuarios en el trabajo diario. Suelen incorporar además tareas administrativas, como la creación de copias de seguridad o el arreglo de problemas de red.

9.2.- Usuarios

- **Expertos.** Utilizan el lenguaje de manipulación de datos (DML) para acceder a la base de datos. Son usuarios que utilizan la base de datos para la gestión avanzada de decisiones.
- **Habituales.** Utilizan las aplicaciones creadas por los desarrolladores para consultar y actualizar los datos. Son los que trabajan en la empresa a diario con estas herramientas y con los propios datos.
- **Ocasionales.** Son usuarios que utilizan un acceso mínimo a la base de datos a través de una aplicación que permite consultar ciertos datos. Serían, por ejemplo, los usuarios que consultan el horario de trenes a través de Internet.

10.- Aspectos legales: la LOPD y el RGPD

A partir de la publicación de la **Ley Orgánica 15/1999**, de 13 de diciembre, de **Protección de Datos de Carácter Personal (LOPD)**, todas las entidades que almacenaran datos de carácter personal estaban obligadas a cumplir unas normas en cuanto a la seguridad de esos datos personales.

Según lo establecido en esta Ley, siempre que se procediera al tratamiento de datos personales ("cualquier información concerniente a personas físicas identificadas o identificables") que supusiera la inclusión de dichos datos en un fichero ("conjunto organizado de datos de carácter personal, cualquiera que fuere la forma o modalidad de su creación, almacenamiento, organización y acceso"), el fichero se encontraría sometido a la Ley, siendo obligatoria su inscripción en el Registro General de Protección de Datos, conforme dispone el artículo 26.

El artículo 9 de esta Ley establecía en su punto 1 que "el responsable del fichero y, en su caso, el encargado del tratamiento, deberán adoptar las medidas de índole técnica y organizativas necesarias que garanticen la seguridad de los datos de carácter personal y eviten su alteración, pérdida, tratamiento o acceso no autorizado, habida cuenta del estado de la tecnología, la naturaleza de los datos almacenados y los riesgos a que están expuestos, ya provengan de la acción humana o del medio físico o natural".

Por ello, dentro de cualquier entidad que tratase con datos personales se debía tener en cuenta la importancia de la correcta gestión de los mismos, tomando medidas para que las personas encargadas del tratamiento de los datos cumplieran las obligaciones que les imponía la citada LOPD:

- Inscripción de ficheros en la Agencia Española de Protección de Datos (AEPD).
- Adopción de medidas especiales de seguridad (protección de acceso, copias de seguridad).

- Documentación de seguridad.
- Deber de información.
- Deber de guardar secreto.

Hoy en día, la transformación digital ha llevado a una exposición excesiva de los datos personales, por lo que la Unión Europea ha optado por ampliar la protección de los derechos individuales mediante la creación **del Reglamento General de Protección de Datos (RGPD)** relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales y a la libre circulación de estos datos. Entró en vigor el 25 de mayo de 2016 y, tras un período transitorio de 2 años, se empezó a aplicar obligatoriamente el 25 de mayo de 2018. Muchos aspectos de este Reglamento han estado durante más de un año pendientes de regular por parte de cada uno de los Estados Miembros. En España, el 10 de noviembre de 2017, fue aprobado para ese fin por el Consejo de Ministros el Proyecto de Ley Orgánica de Protección de Datos, pero debido a la compleja situación política existente en ese momento, se demoró su aprobación durante unos meses, más allá del 25 de mayo de 2018 que establecía como fecha tope el RGPD.

Debido a esta demora, y para avanzar en la adaptación de la normativa europea a nivel español; en todos aquellos aspectos que no requerían ser regulados por una Ley Orgánica, por no tratarse de derechos fundamentales, se aprobó el **Real Decreto 5/2018**, de 27 de julio, **de medidas urgentes para la adaptación del Derecho español a la normativa de la Unión Europea en materia de protección de datos**, y de esta forma dar cobertura legal a los aspectos que debían ser de forma urgente regulados para que pueda ser aplicada la normativa europea, y no esperar a la aprobación de la Ley Orgánica. Este Decreto Ley ha estado vigente hasta el 5 de diciembre de 2018, cuando definitivamente se aprobó la **Ley Orgánica 3/2018**, de 5 de diciembre, **de Protección de Datos Personales y garantía de los derechos digitales**, que sustituye definitivamente a la LOPD de 1999 (salvo en unos aspectos muy concretos previstos en la disposición adicional decimocuarta y transitoria cuarta de la Ley 3/2018).

El incumplimiento del nuevo RGPD contempla sanciones y multas que pueden alcanzar cuantías de hasta 20 millones de euros o el 4% del volumen de negocio del ejercicio anterior.

Los puntos vitales de este RGPD en cuanto a los cambios y obligaciones que afectan a las empresas son:

- **Delegado de Protección de Datos (DPD/DPO).** El Reglamento obliga a quienes realicen ciertos tratamientos, a nombrar un DPO, que podrá ser externo o interno. Un DPO deberá ser una persona experta en Protección de Datos y en métodos y técnicas de Seguridad de la información.
- **Exigencia de la realización de una evaluación** de impacto relativa a la protección de datos para ciertos tratamientos. La AEPD publicará una lista de los tipos de operaciones de tratamiento a los que les será exigible.
- **Violaciones de la seguridad de los datos personales.** Obligatoriedad de comunicarlas en un plazo de 72 horas a la Agencia Española de Protección de Datos, y en casos graves, a los propios afectados.
- **Se elimina el consentimiento tácito (por silencio),** lo que obligará a las empresas a recabar un nuevo consentimiento para poder mantener todos aquellos datos que en el pasado se obtuvieron tácitamente o buscarles otra

cobertura legal. El Reglamento pide que el consentimiento, con carácter general, sea libre, informado, específico e inequívoco. Para poder considerar que el consentimiento es “incuestionable”, el Reglamento requiere que haya una declaración de los interesados o una acción positiva que apunte al acuerdo del interesado. La aceptación no puede deducirse del silencio o de la inacción de los ciudadanos. Se exige que el consentimiento tenga que ser “manifiesto” en determinados casos, como puede ser para autorizar el tratamiento de datos sensibles. Por tanto, el consentimiento tiene que ser verificable y quienes recopilen datos personales deben poder probar que el afectado les concedió su consentimiento.

- Se amplían las obligaciones de información a los afectados, lo que obligará ponerles al día en dicha información a los ya existentes.
- Se amplía el contenido mínimo en los contratos de acceso a datos por parte de terceros, por lo que deberán de establecerse de nuevo los contratos con los encargados de tratamiento, dado que los actuales no cumplen con el RGPD.
- El RGPD no establece diferenciación entre datos personales y datos ‘profesionales’ (datos de contacto de personas físicas que prestan sus servicios en una persona jurídica y empresarios individuales) como estableció el vigente Reglamento, lo que obligará a las empresas a tener que realizar acciones informativas a esta categoría de datos.

Además, un nuevo elemento que se ha introducido y que afecta significativamente al usuario final es el derecho al olvido, que es aquel que tienen los ciudadanos a solicitar, y conseguir de los encargados, que los datos personales sean suprimidos cuando estos ya no sean necesarios para el fin para el que fueron reunidos, cuando se haya revocado el consentimiento o cuando estos se hayan obtenido de forma ilegal.

11.- Bases de datos distribuidas

Frente a un sistema centralizado, en el que todos los componentes de la base de datos residen en un único lugar físico, las bases de datos distribuidas se presentan como aquella arquitectura de bases de datos en la que todos los componentes se distribuyen en distintos ordenadores conectados a través de una red de trabajo.

Una característica fundamental de los sistemas de bases de datos distribuidos (SGBDD) es la denominada transparencia en la distribución, lo que implica que cuando un usuario accede a la base de datos, todo lo que ocurre es transparente y queda al margen de cualquier detalle de cómo se ejecuta la transacción, es decir, al usuario se le presenta un esquema que no incluye información sobre la distribución de los datos. Es el software cliente quien consulta el catálogo del SGBDD para conocer la ubicación de los datos y poder así descomponer la consulta y distribuirla entre los distintos servidores.

Hoy en día son muchas las **ventajas** que ofrecen las bases de datos distribuidas frente a las centralizadas:

- **Mejora del rendimiento.** Cuando grandes bases de datos se distribuyen en varios sitios, las consultas y las transacciones que afectan a un solo sitio son más rápidas al ser más pequeña la base de datos local sobre la que interaccionan. Las consultas y las transacciones que afectan a varios sitios

a la vez pueden llevarse a cabo en paralelo, reduciendo de esta manera el tiempo de respuesta.

- **Fiabilidad.** Representa la probabilidad de que un sistema esté activo en un tiempo dado. Al distribuirse los datos, es más fácil asegurar la fiabilidad del sistema, ya que, si falla algún sitio, es poco probable que ese fallo afecte a la mayoría de las transacciones.
- **Disponibilidad.** Representa la probabilidad de que un sistema esté activo de manera continuada durante un tiempo. Esta característica se ve mejorada mucho más por la replicación de datos en varios sistemas.
- **Escalabilidad.** Distribuyendo una base de datos en distintas ubicaciones se permite incrementar de forma sencilla los recursos en cualquier momento para acomodar el sistema a las demandas de los usuarios y las aplicaciones.
- **Tipos de aplicaciones existentes** actualmente, que tienen un marcado carácter distribuido al estar sus componentes dispersos en distintos sitios.


Por el contrario, también tienen inconvenientes, como una mayor dificultad en la administración, una mayor dependencia de las redes de comunicaciones, un mayor coste de implementación..., lo que hace que estos SGBDD sean más complejos que los centralizados debiendo, por tanto, incorporar:

- Acceso a sitios remotos e intercambiar información con los mismos para la ejecución de consultas y transacciones.
- Catálogo con información sobre cómo están distribuidos y replicados los datos del sistema distribuido.
- Integridad en los permisos sobre datos replicados.
- Consistencia de las copias de un elemento replicado.
- Recuperación del sistema en caso de caída.

Para definir la arquitectura de un SGBDD hay que tener presentes tres parámetros:

- **Autonomía,** que tiene que ver con quién tiene el control sobre qué datos del SGBDD. Puede ser:
 - Integración fuerte: un equipo hace de coordinador enviando las solicitudes de información a los equipos donde resida la información.
 - Sistema semiautónomo: los SGBD son independientes, pero participan en el conjunto pudiendo compartir parte de sus datos.
 - Sistema aislado: el SGBD no tiene constancia de que existan otros gestores.
- **Distribución de los datos** a lo largo del sistema, clasificándose en:
 - Distribución cero: no hay distribución de datos.
 - Cliente-servidor: los datos residen en los servidores, mientras que los clientes proveen una interfaz de acceso a los mismos además de otras posibles funcionalidades como caché de consultas.
 - Servidores colaborativos: no se distingue entre servidores y clientes, cada máquina tiene toda la funcionalidad del SGBDD.
- **Heterogeneidad de los componentes del sistema en niveles como hardware, comunicaciones y sistema operativo.**

De la importancia y la combinación de ellos pueden surgir numerosas posibilidades de organización, como se puede observar en la siguiente imagen.



12.- Big-Data

Big-Data es un término bajo el que se agrupan toda clase de **técnicas de tratamiento de grandes volúmenes de datos**, fuera de los análisis y herramientas clásicas. Este concepto engloba muchas ideas y aproximaciones, pero todas con un objetivo común: **extraer información de valor de los datos**, de forma que pueda ser de ayuda para las decisiones y procesos de negocio. El concepto de Big-Data se encuentra muchas veces hermanado con otros términos como *Data Science*, *Analytics* o *Data Mining*, que expresan igualmente el objetivo de extraer valor de los datos.

No existe una cantidad precisa de datos que permita hablar de Big-Data. Los límites que se manejan suelen girar en torno a **terabytes, petabytes o zettabytes**. Trabajar con semejante cantidad de información exige la utilización de recursos tecnológicos avanzados.

El Big-Data se vuelca en bases de datos de distintos tipos. Es posible administrar datos **estructurados** (cuyo formato ya está definido), **datos semiestructurados** (no están limitados a un campo específico, pero cuentan con marcadores para la distinción de elementos) y **datos no estructurados** (sin formato específico). Los datos, por otra parte, pueden capturarse y visualizarse mediante diversas herramientas informáticas de acuerdo a la necesidad.

La importancia de este concepto es incalculable para muchas empresas, ya que les permite obtener respuestas a miles de preguntas esenciales para su correcto funcionamiento a una velocidad que sería imposible por medio del trabajo humano. Gracias a la versatilidad que ofrecen los diferentes sistemas de manipulación y consulta de datos, es posible obtener resultados “a medida”, fáciles de comprender.

Las consultas y el análisis de Big-Data sirven para orientar mejor los negocios, acentuando las decisiones acertadas, evitando las potencialmente perjudiciales y

apuntando a aquéllas que no han sido tomadas hasta el momento pero que podrían acarrear un crecimiento importante.

Para conocer las **características** de la palabra Big-Data podemos centrarnos en explicar las 5V:

- **Volumen.** Es una de las características más destacadas y asociada al concepto de Big-Data. La generación de datos en un día es superior a la de hace veinte años, todos esos datos desestructurados que se guardan tienen un inmenso potencial. Por eso, para este gran volumen de información se requiere que se tenga una correcta orientación de las estrategias para ponerlos a filtrar y así ofrecer un ahorro de tiempo.
- **Velocidad.** El tiempo siempre es importante y el cómo se afronta también. Todo el proceso de tratamiento de datos pide agilidad para extraer el valor de negocio a toda la información que se tiene y que de esta manera no se pierda ninguna oportunidad. **El tiempo de procesamiento de la información tiene que ser un factor fundamental para que el tratamiento aporte ventajas y marquen la diferencia.**
- **Variedad.** Es fundamental **hacer frente a la variedad de datos** que aumenta el grado de complejidad, tanto en el almacenamiento de información como en el análisis. Por ello, hay que **dar uniformidad a los datos que tienen origen heterogéneo** porque una de las fortalezas del Big-Data es que se puede conjugar y combinar todo tipo de información para alcanzar un todo homogéneo.
- **Veracidad.** Como se ha dicho antes, existe mucha variedad en toda la información que se recaba; por ello es conveniente **encontrar las herramientas necesarias para comprobar la veracidad de la información recibida.** Para ello, se tiene que ejercer una limpieza en los datos para asegurarse el mayor aprovechamiento de los mismos.
- **Valor.** **Toda la información recogida tiene que servir para aportar valor a las empresas,** los gobiernos o la sociedad porque si no, no da lugar a almacenar ni administrar. En definitiva, la clave está en cómo obtener la mejor información, el mejor valor y conocimiento para sacar la mayor rentabilidad.

Todo proyecto centrado en Big-Data se basa en tres **capas tecnológicas**:

- **Almacenamiento.** **Los recursos hardware y software permiten el almacenamiento distribuido y redundante de los datos,** facilitando su acceso y disponibilidad, y evitando los grandes almacenes únicos de datos. Responden a dónde tener los datos.
- **Procesamiento.** **Las herramientas de procesamiento de los datos dan la base tecnológica para operar con grandes volúmenes de información batch o flujos rápidos de datos en tiempo real.** Responden a cómo trabajar con los datos.
- **Análisis.** Por último, los algoritmos y métodos realizan el análisis de los datos, produciendo información de valor para el negocio. Responden a qué hacer con los datos.

Anexo.- Estándares

Es uno de los aspectos que todavía sigue pendiente. Desde la aparición de los primeros gestores de base de datos se intentó llegar a un acuerdo para que hubiera una estructura común para todos ellos, a fin de que el aprendizaje y manejo de este software fuera más provechoso y eficiente. El acuerdo nunca se ha conseguido del todo, aunque sí hay unas cuentas propuestas de estándares que funcionan como tales.

Los intentos por conseguir una estandarización han estado promovidos por organismos de todo tipo. Algunos son estatales, otros privados y otros promovidos por los propios usuarios. Los tres que han tenido gran relevancia en el campo de las bases de datos son **ANSI/SPARC/X3**, **CODASYL** y **ODMG** (éste sólo para las bases de datos orientadas a objetos). Algunos de estos organismos son:

- **ISO** (*International Organization for Standardization*). Es un organismo internacional de definición de estándares de gran prestigio.
- **IEC** (*International Electrotechnical Commission*). Organismo de definición de normas en ambientes electrónicos. En definitiva, es la parte de ISO, dedicada a la creación de estándares.
- **JTC 1** (*Joint Technical Committee*). Comité parte de IEC dedicado a la tecnología de la información (informática). En el campo de las bases de datos, el subcomité SC 21 (en el que participan otros organismos nacionales, como el español AENOR) posee un grupo de trabajo llamado **WG 3** que se dedica a las bases de datos. Este grupo de trabajo es el que define la estandarización del lenguaje SQL entre otras cuestiones.
- **CodasyI** (*Conference on Data System Languages*) es el nombre de una conferencia iniciada en el año 1959 y que dio lugar a un organismo con la idea de conseguir un lenguaje estándar para la mayoría de máquinas informáticas. Su primera tarea fue desarrollar el lenguaje COBOL y otros elementos del análisis, diseño y la programación de ordenadores.
- **ANSI-SPARC**: **ANSI** (*American National Standard Institute*) es un organismo científico de Estados Unidos que ha definido diversos estándares en el campo de las bases de datos. **SPARC** (*Standard Planning and Requirements Committee*) es un comité de planificación de estándares y requerimientos y está encargado de los estándares en Sistemas Informáticos, en especial del campo de las bases de datos. En la actualidad ANSI habla ya de un único modelo de sistema de bases de datos, el basado en los 3 niveles antes comentados: externo, conceptual e interno.